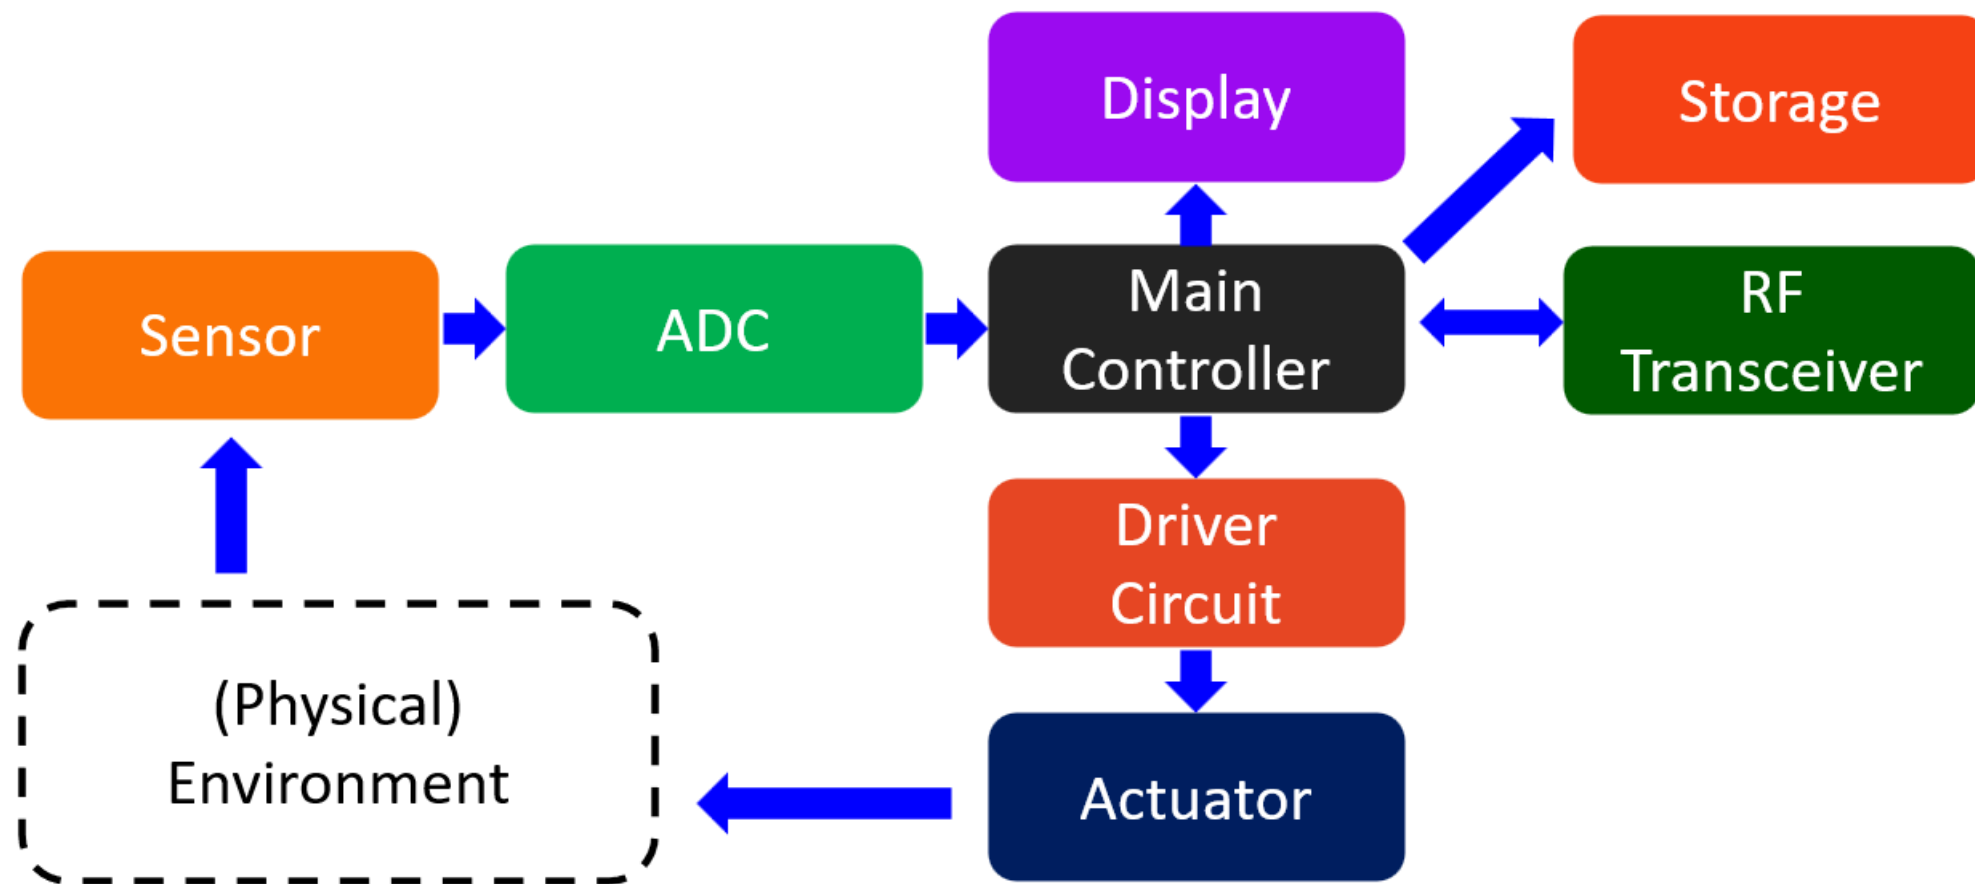



Data Acquisition, Sensor Filtering and Fusion Techniques

Embedded System Architecture



Embedded AI Data Flow



- **Sensor** Berfungsi untuk mengumpulkan data dari lingkungan, seperti suhu, kelembaban, akselerasi, atau sinyal biometrik.
- **Main Controller** bertanggung jawab untuk memproses data dari sensor dan meneruskannya ke modul AI.

- **AI (Artificial Intelligence)** Berada dalam **Main Controller** untuk menganalisis data yang diterima dari sensor menggunakan model Machine Learning atau Deep Learning untuk melakukan klasifikasi, deteksi pola, atau pengambilan keputusan.
- Setelah diproses oleh AI, data digunakan untuk berbagai keperluan, seperti **kontrol otomatis, prediksi, atau pemantauan kondisi tertentu**.
- Output dapat dikirim ke **aktor (motor, alarm, tampilan layar), cloud, atau sistem lain** untuk tindakan lebih lanjut.

Contoh Implementasi

- **Sistem IoT untuk pemantauan lingkungan:** Sensor suhu mengirim data ke controller, AI memprediksi tren suhu, dan sistem memberikan peringatan jika suhu terlalu tinggi.
- **Embedde System untuk kesehatan:** Sensor detak jantung mengirim data ke AI dalam microcontroller, lalu AI menganalisis apakah detak jantung normal atau ada indikasi penyakit.

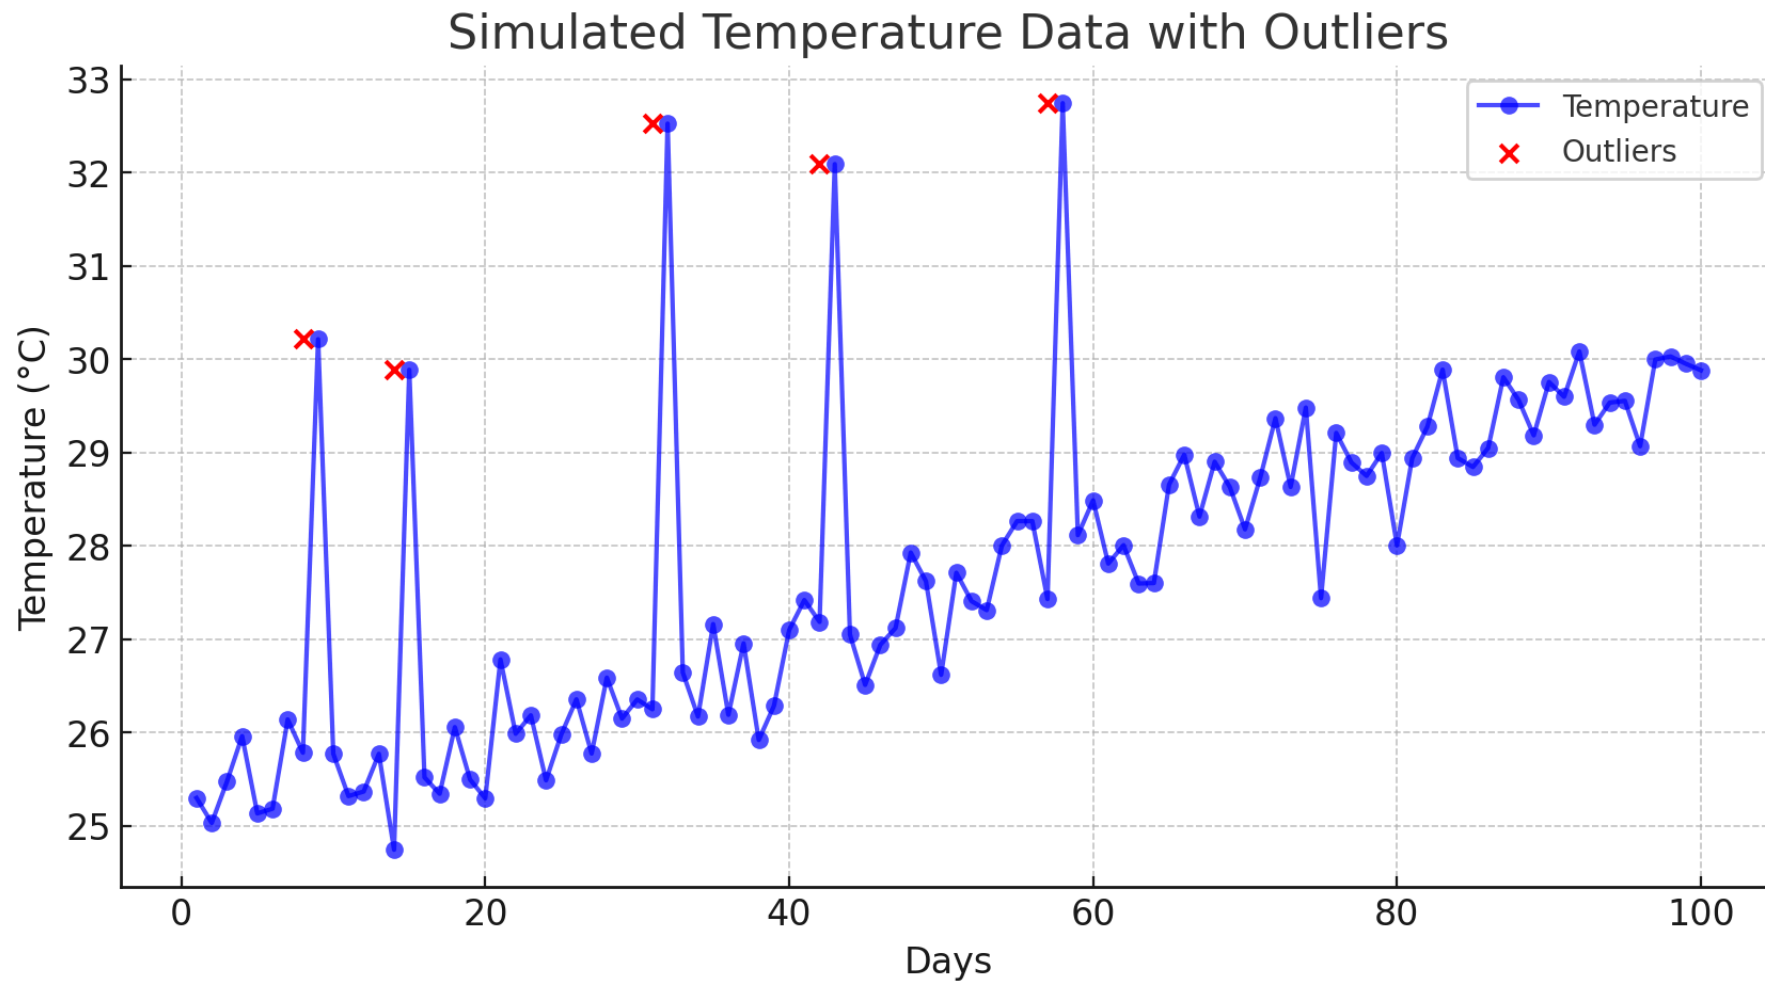
Mengakses Data dari Sensor

- Menggunakan protokol komunikasi seperti **I2C, SPI, UART, atau ADC** untuk membaca data dari sensor.
- Memanfaatkan **microcontroller (Arduino, ESP32, STM32) atau single-board computer (Raspberry Pi)** untuk menangkap data.
- Menyimpan data ke dalam format CSV, JSON, atau database untuk analisis lebih lanjut.

Membangun Dataset

- **Preprocessing:** Membersihkan data dari noise dan outlier.
- **Normalisasi:** Menyesuaikan skala data agar lebih mudah diproses.
- **Labeling:** Jika diperlukan untuk supervised learning.

Data Cleaning



Normalisasi

Temperature (°C)	Humidity (%)	Pressure (hPa)	Acceleration (m/s ²)
25	60	1000	0.5
30	65	1012	1.2
35	70	1025	0.8
40	75	1030	2.5
45	80	1045	3.0

Kenapa Perlu Normalisasi?

Data ini memiliki rentang nilai yang berbeda-beda (**Temperature** vs. **Pressure** vs. **Acceleration**). Jika langsung digunakan dalam model Machine Learning, fitur dengan skala lebih besar (seperti **Pressure**) bisa mendominasi hasil prediksi.

Metode Normalisasi yang Bisa Digunakan

- **Min-Max Scaling** (Skala [0,1]):
- $$X_{\text{scaled}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$
- **Standardization (Z-Score Normalization)** (Distribusi normal dengan mean = 0, std = 1):
- $$X_{\text{standardized}} = \frac{X - \mu}{\sigma}$$
- **Gunakan Min-Max Scaling** jika algoritma yang digunakan sensitif terhadap skala fitur.
- **Gunakan Z-Score Standardization** jika data perlu didistribusikan secara

```
import numpy as np
import matplotlib.pyplot as plt

# 1. Simulasi data suhu (seperti pada contoh sebelumnya)
np.random.seed(42)
time = np.linspace(0, 10, 500) # 10 detik, 500 sampel
true_temperature = 25 + 2 * np.sin(2 * np.pi * 0.1 * time) # Suhu sebenarnya
sensor_temperature = true_temperature + np.random.normal(0, 1, size=len(time)) # Noise ±1°C

# 2. Min-Max Scaling
X_min = np.min(sensor_temperature)
X_max = np.max(sensor_temperature)
sensor_temperature_minmax = (sensor_temperature - X_min) / (X_max - X_min)

# 3. Z-Score Standardization
X_mean = np.mean(sensor_temperature)
X_std = np.std(sensor_temperature)
sensor_temperature_zscore = (sensor_temperature - X_mean) / X_std

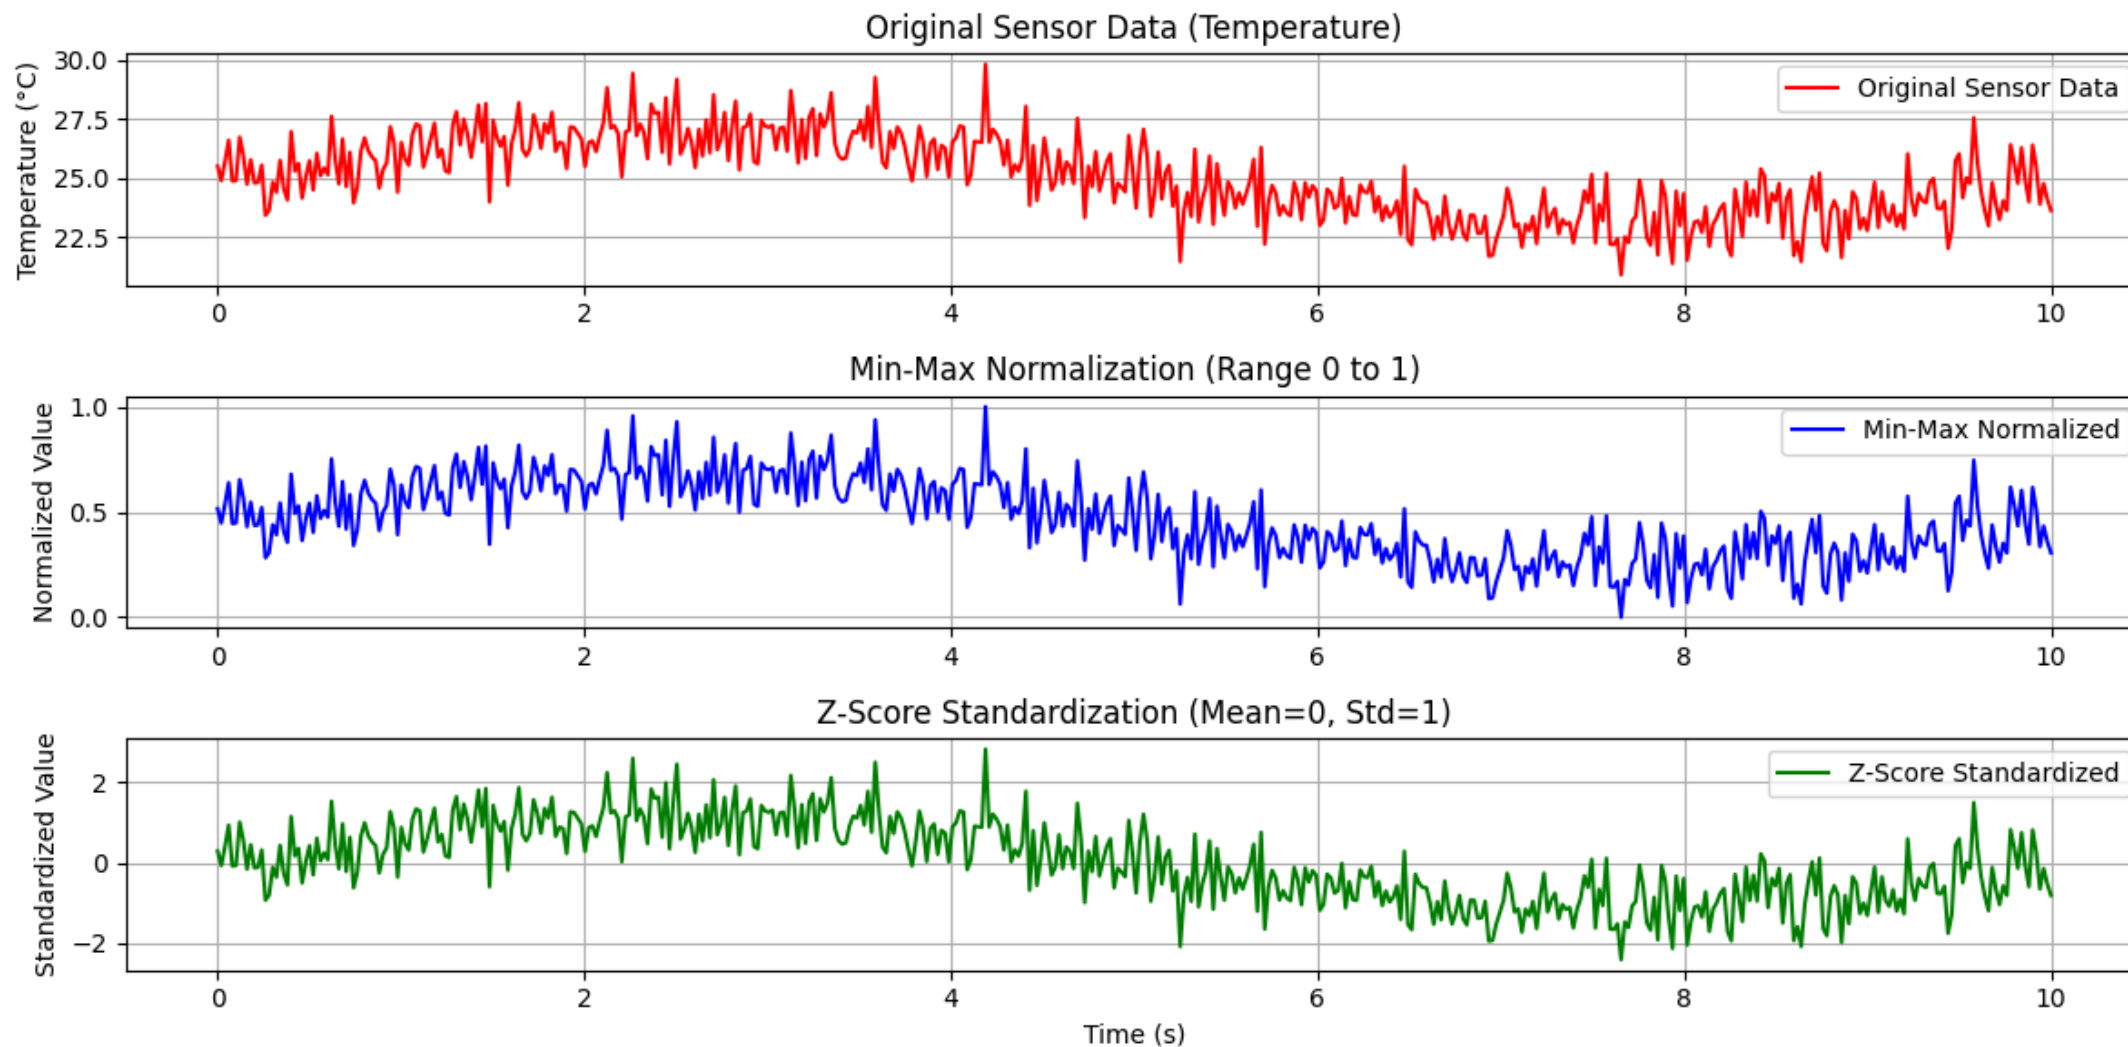
# 4. Visualisasi hasil normalisasi
plt.figure(figsize=(12, 6))

plt.subplot(3, 1, 1)
plt.plot(time, sensor_temperature, 'r-', label="Original Sensor Data")
plt.title("Original Sensor Data (Temperature)")
plt.ylabel("Temperature (°C)")
plt.legend()
plt.grid(True)

plt.subplot(3, 1, 2)
plt.plot(time, sensor_temperature_minmax, 'b-', label="Min-Max Normalized")
plt.title("Min-Max Normalization (Range 0 to 1)")
plt.ylabel("Normalized Value")
plt.legend()
plt.grid(True)

plt.subplot(3, 1, 3)
plt.plot(time, sensor_temperature_zscore, 'g-', label="Z-Score Standardized")
plt.title("Z-Score Standardization (Mean=0, Std=1)")
plt.ylabel("Standardized Value")
plt.xlabel("Time (s)")
plt.legend()
plt.grid(True)

plt.tight_layout()
plt.show()
```



Labeling

Temperature (°C)	Humidity (%)	Pressure (hPa)	Acceleration (m/s ²)	Label
25	60	1000	0.5	Safe
30	65	1012	1.2	Safe
35	70	1025	0.8	Safe
40	75	1030	2.5	High Risk
45	80	1045	3.0	Extreme Condition

Introduction to Sensor Filtering

Sensor filtering digunakan untuk mengurangi noise dan memperbaiki keakuratan data sensor sebelum diproses lebih lanjut.

Kalman Filter

- Algoritma berbasis **probabilistic estimation** yang digunakan untuk **prediksi** dan **koreksi** nilai sensor berdasarkan model sistem dan pengukuran aktual.
- **Contoh penggunaan:** Estimasi posisi drone menggunakan data dari IMU (gyroscope & accelerometer).


```
from pykalman import KalmanFilter
import numpy as np
from matplotlib import pyplot as plt

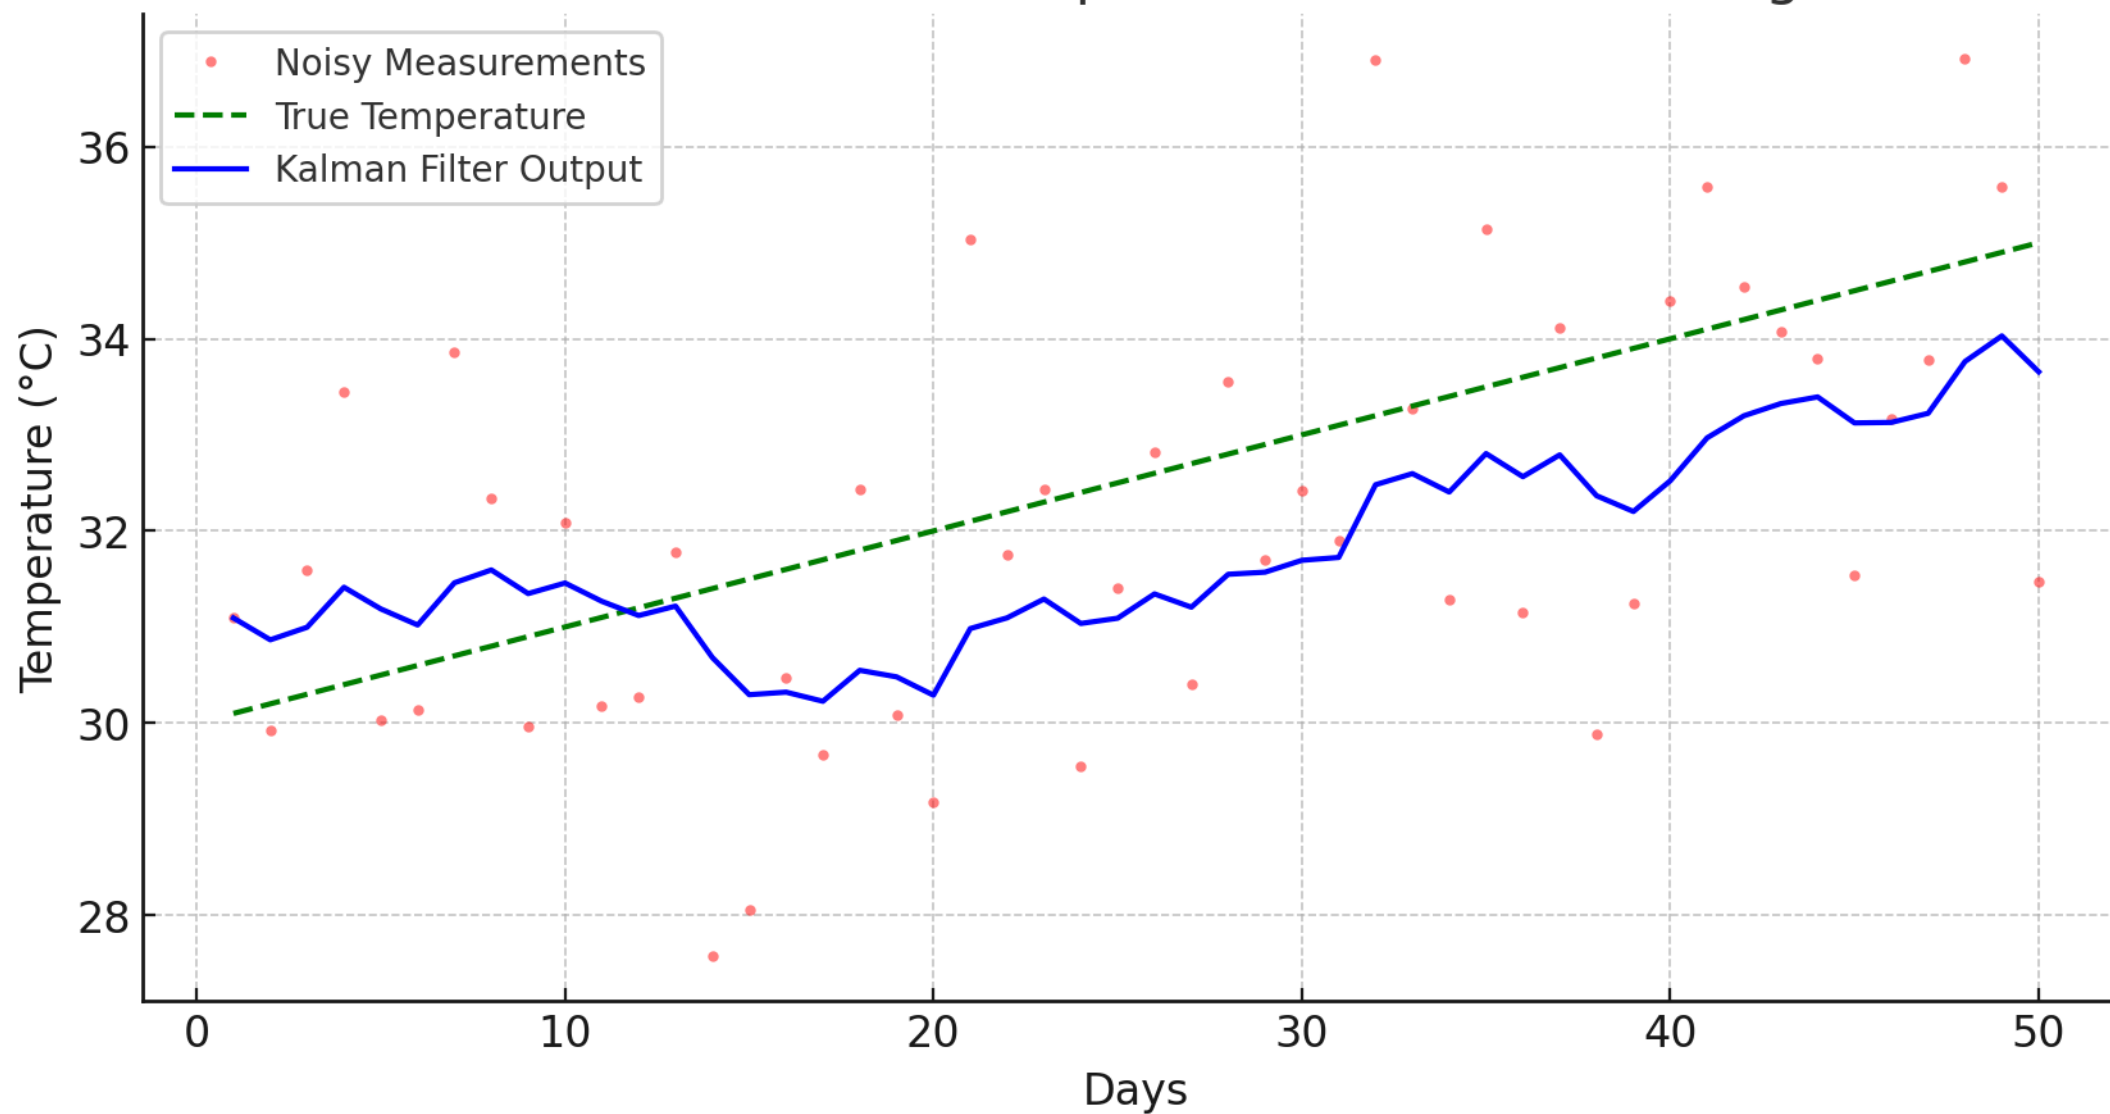
# Simulasi data noisy suhu (misalnya dari sensor)
np.random.seed(42)
days = np.arange(1, 51) # 50 hari
true_temperature = 30 + 0.1 * days # Tren suhu meningkat
noisy_temperature = true_temperature + np.random.normal(0, 2, size=len(days)) # Tambahkan noise

# Inisialisasi Kalman Filter
kf = KalmanFilter(initial_state_mean=noisy_temperature[0],
                  n_dim_obs=1,
                  transition_matrices=[1],
                  observation_matrices=[1],
                  observation_covariance=4, # Variance of observation noise (sigma^2)
                  transition_covariance=0.1) # Model system noise

# Melakukan estimasi dengan Kalman Filter
filtered_temperature, _ = kf.filter(noisy_temperature)

# Plot hasil
plt.figure(figsize=(10, 5))
plt.plot(days, noisy_temperature, 'r.', alpha=0.5, label="Noisy Measurements")
plt.plot(days, true_temperature, 'g--', label="True Temperature")
plt.plot(days, filtered_temperature, 'b-', label="Kalman Filter Output")
plt.xlabel("Days")
plt.ylabel("Temperature (°C)")
plt.title("Kalman Filter for Temperature Data Smoothing")
plt.legend()
plt.grid(True)
plt.show()
```

Kalman Filter for Temperature Data Smoothing



- **Noisy Measurements (Titik Merah):** Data suhu yang dikumpulkan dari sensor memiliki noise yang cukup besar.
- **True Temperature (Garis Putus-Putus Hijau):** Nilai suhu sebenarnya yang mengikuti tren kenaikan.
- **Kalman Filter Output (Garis Biru):** Estimasi suhu hasil filtering menggunakan Kalman Filter, yang lebih halus dan mendekati suhu sebenarnya.

1. Tahap Prediksi (Prediction Step)

Pada tahap ini, Kalman Filter memprediksi keadaan sistem berdasarkan model sebelumnya.

- **Prediksi keadaan (state estimate):**

$$\hat{x}_k^- = A\hat{x}_{k-1} + Bu_k$$

- \hat{x}_k^- = prediksi keadaan pada waktu k
- A = matriks transisi keadaan
- \hat{x}_{k-1} = keadaan sebelumnya
- B = matriks kontrol (jika ada kontrol input)
- u_k = kontrol input (jika ada)

- **Prediksi kovarians error:**

$$P_k^- = AP_{k-1}A^T + Q$$

- P_k^- = prediksi kovarians error
- P_{k-1} = kovarians error sebelumnya
- Q = kovarians noise proses

2. Tahap Update (Correction Step)

Setelah prediksi, Kalman Filter memperbarui estimasi berdasarkan pengukuran baru.

- **Menghitung Kalman Gain:**

$$K_k = P_k^- H^T (H P_k^- H^T + R)^{-1}$$

- K_k = Kalman Gain
- H = matriks observasi
- R = kovarians noise pengukuran

- **Memperbarui estimasi keadaan:**

$$\hat{x}_k = \hat{x}_k^- + K_k(z_k - H\hat{x}_k^-)$$

- z_k = pengukuran baru

- **Memperbarui kovarians error:**

$$P_k = (I - K_k H)P_k^-$$

- I = matriks identitas

```
import numpy as np
import matplotlib.pyplot as plt

# 1. Simulasi data suhu
np.random.seed(42)
time = np.linspace(0, 10, 500) # 10 detik, 500 sampel

# Suhu sebenarnya (misalnya suhu ruangan berubah perlahan)
true_temperature = 25 + 2 * np.sin(2 * np.pi * 0.1 * time)

# Data sensor dengan noise
sensor_temperature = true_temperature + np.random.normal(0, 1, size=len(time)) # noise ±1°C

# 2. Inisialisasi Kalman Filter
x_est = np.zeros_like(time) # Estimasi suhu
P = np.zeros_like(time) # Kovarians error

x_est[0] = sensor_temperature[0] # Inisialisasi dengan nilai sensor pertama
P[0] = 1 # Inisialisasi variansi awal

Q = 0.01 # Variansi noise proses (tuning parameter)
R = 1.0 # Variansi noise pengukuran (tuning parameter)


# 3. Loop Kalman Filter
for k in range(1, len(time)):
    # *** Prediction Step ***
    x_pred = x_est[k-1] # Asumsi suhu berubah perlahan (tanpa model kecepatan)
    P_pred = P[k-1] + Q # Prediksi kovarians error

    # *** Update Step ***
    K = P_pred / (P_pred + R) # Kalman Gain
    x_est[k] = x_pred + K * (sensor_temperature[k] - x_pred) # Update estimasi suhu
    P[k] = (1 - K) * P_pred # Update kovarians error

# 4. Visualisasi hasil
plt.figure(figsize=(10, 6))
plt.plot(time, true_temperature, 'k-', label='True Temperature', linewidth=2)
plt.plot(time, sensor_temperature, 'r.', alpha=0.5, label='Sensor Measurement (Noisy)')
plt.plot(time, x_est, 'b-', label='Kalman Filter')

plt.title("Kalman Filter on Temperature Sensor Data")
plt.xlabel("Time (s)")
plt.ylabel("Temperature (°C)")
plt.legend()
plt.grid(True)
plt.show()
```


Kalman Filter on Temperature Sensor Data



```
import numpy as np
import matplotlib.pyplot as plt

# 1. Inisialisasi data simulasi
np.random.seed(42)
time = np.linspace(0, 10, 500) # 10 detik, 500 sampel
dt = time[1] - time[0] # Delta t

# Sudut pitch sebenarnya (sinusoidal)
true_pitch = 10 * np.sin(2 * np.pi * 0.5 * time)

# Gyroscope rate (turunan dari pitch)
true_gyro_rate = np.gradient(true_pitch, dt)

# Tambahkan noise
gyro_rate_noisy = true_gyro_rate + np.random.normal(0, 5, size=len(time)) # noise ±5 deg/s
acc_pitch_noisy = true_pitch + np.random.normal(0, 2, size=len(time)) # noise ±2 deg

# 2. Inisialisasi variabel Kalman Filter
x_est = np.zeros_like(time) # Estimasi sudut
P = np.zeros_like(time) # Kovarians error

x_est[0] = acc_pitch_noisy[0] # Inisialisasi dengan sudut dari accelerometer
P[0] = 1 # Inisialisasi variansi awal

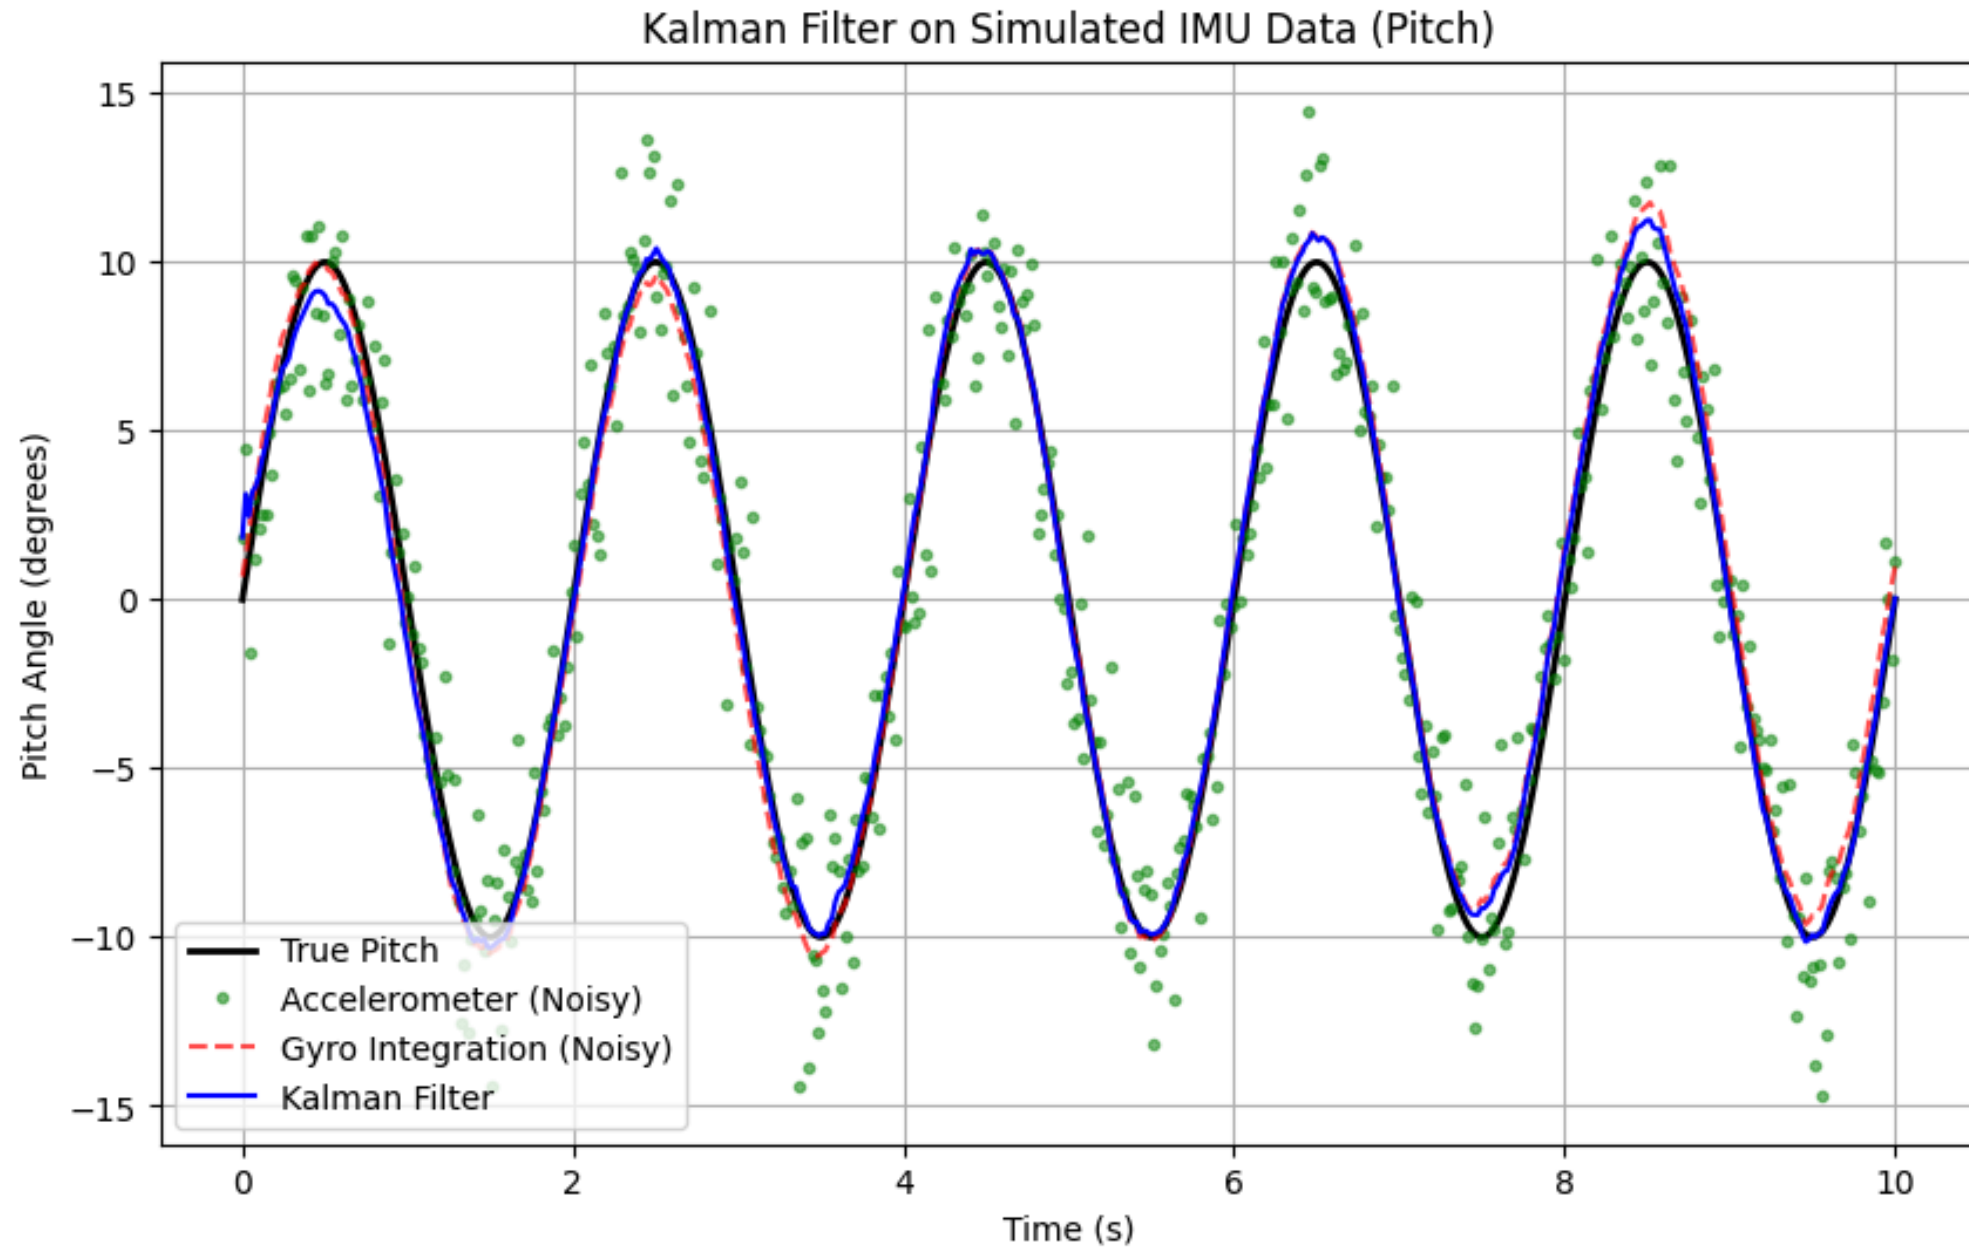
Q = 0.001 # Variansi noise proses (tuning parameter)
R = 2.0 # Variansi noise pengukuran (tuning parameter)

# 3. Loop Kalman Filter
for k in range(1, len(time)):
    # *** Prediction Step ***
    x_pred = x_est[k-1] + gyro_rate_noisy[k] * dt # Prediksi sudut dengan gyro
    P_pred = P[k-1] + Q # Prediksi kovarians error

    # *** Update Step ***
    K = P_pred / (P_pred + R) # Kalman Gain
    x_est[k] = x_pred + K * (acc_pitch_noisy[k] - x_pred) # Update estimasi sudut
    P[k] = (1 - K) * P_pred # Update kovarians error

# 4. Visualisasi hasil
plt.figure(figsize=(10, 6))
plt.plot(time, true_pitch, 'k-', label='True Pitch', linewidth=2)
plt.plot(time, acc_pitch_noisy, 'g.', alpha=0.5, label='Accelerometer (Noisy)')
plt.plot(time, gyro_rate_noisy.cumsum() * dt, 'r--', alpha=0.7, label='Gyro Integration (Noisy)')
plt.plot(time, x_est, 'b-', label='Kalman Filter')

plt.title("Kalman Filter on Simulated IMU Data (Pitch)")
plt.xlabel("Time (s)")
plt.ylabel("Pitch Angle (degrees)")
plt.legend()
plt.grid(True)
plt.show()
```



b. Complementary Filter

- Metode filtering sederhana yang menggabungkan **sinyal frekuensi rendah** dari satu sensor dan **sinyal frekuensi tinggi** dari sensor lain.
- Sering digunakan untuk **sensor IMU** (accelerometer dan gyroscope) dalam pelacakan orientasi.
- **Keunggulan:** Lebih ringan dibandingkan Kalman Filter dan cocok untuk sistem real-time.
- **Contoh penggunaan:** Meningkatkan akurasi sensor IMU.

Complementary Filter memanfaatkan karakteristik **gyroscope** (akurat pada frekuensi tinggi, tetapi rentan *drift* jangka panjang) dan **accelerometer** (akurat pada frekuensi rendah, tetapi sangat sensitif terhadap getaran dan noise dinamis).

- Komponen **gyroscope** di-*integrasikan* secara terus-menerus untuk mendapatkan perubahan sudut (*angular rate integration*).
- Komponen **accelerometer** digunakan sebagai *baseline* yang lebih stabil untuk sudut statis.

- Kedua sinyal ini dikombinasikan secara komplementer dengan *weighting* tertentu, misalnya menggunakan konstanta α untuk gyroscope dan $(1 - \alpha)$ untuk accelerometer.

Formula *complementary filter* untuk sudut θ adalah:

$$\theta_{\text{combined}}(t) = \alpha [\theta_{\text{combined}}(t - 1) + \omega_{\text{gyro}}(t) \cdot \Delta t] + (1 - \alpha) \theta_{\text{acc}}(t)$$

- $\theta_{\text{combined}}(t)$ = sudut hasil filter pada waktu t .
- $\omega_{\text{gyro}}(t)$ = laju rotasi (rate) dari gyroscope pada waktu t .
- $\theta_{\text{acc}}(t)$ = sudut hasil perhitungan dari data akselerometer (misalnya pitch) pada waktu t .
- α = konstanta yang menentukan bobot gyroscope vs. accelerometer.
- Δt = selang waktu pembacaan sensor.

```
import numpy as np
import matplotlib.pyplot as plt

# 1. Membuat data simulasi
np.random.seed(42)
time = np.linspace(0, 10, 500) # 10 detik, 500 sampel
dt = time[1] - time[0] # Delta t

# Asumsikan ada gerakan pitch sinusoidal + noise
true_pitch = 10 * np.sin(2 * np.pi * 0.5 * time) # amplitudo 10 derajat, freq 0.5 Hz

# Gyroscope rate (derajat/detik) = turunan dari pitch
true_gyro_rate = np.gradient(true_pitch, dt)

# Tambahkan noise
gyro_rate_noisy = true_gyro_rate + np.random.normal(0, 5, size=len(time)) # noise ±5 deg/s
acc_pitch_noisy = true_pitch + np.random.normal(0, 2, size=len(time)) # noise ±2 deg

# 2. Menghitung sudut dari gyroscope dengan integrasi
gyro_angle = np.zeros_like(time)
gyro_angle[0] = acc_pitch_noisy[0] # inisialisasi sudut awal sama dengan accelerometer

for i in range(1, len(time)):
    gyro_angle[i] = gyro_angle[i-1] + gyro_rate_noisy[i] * dt

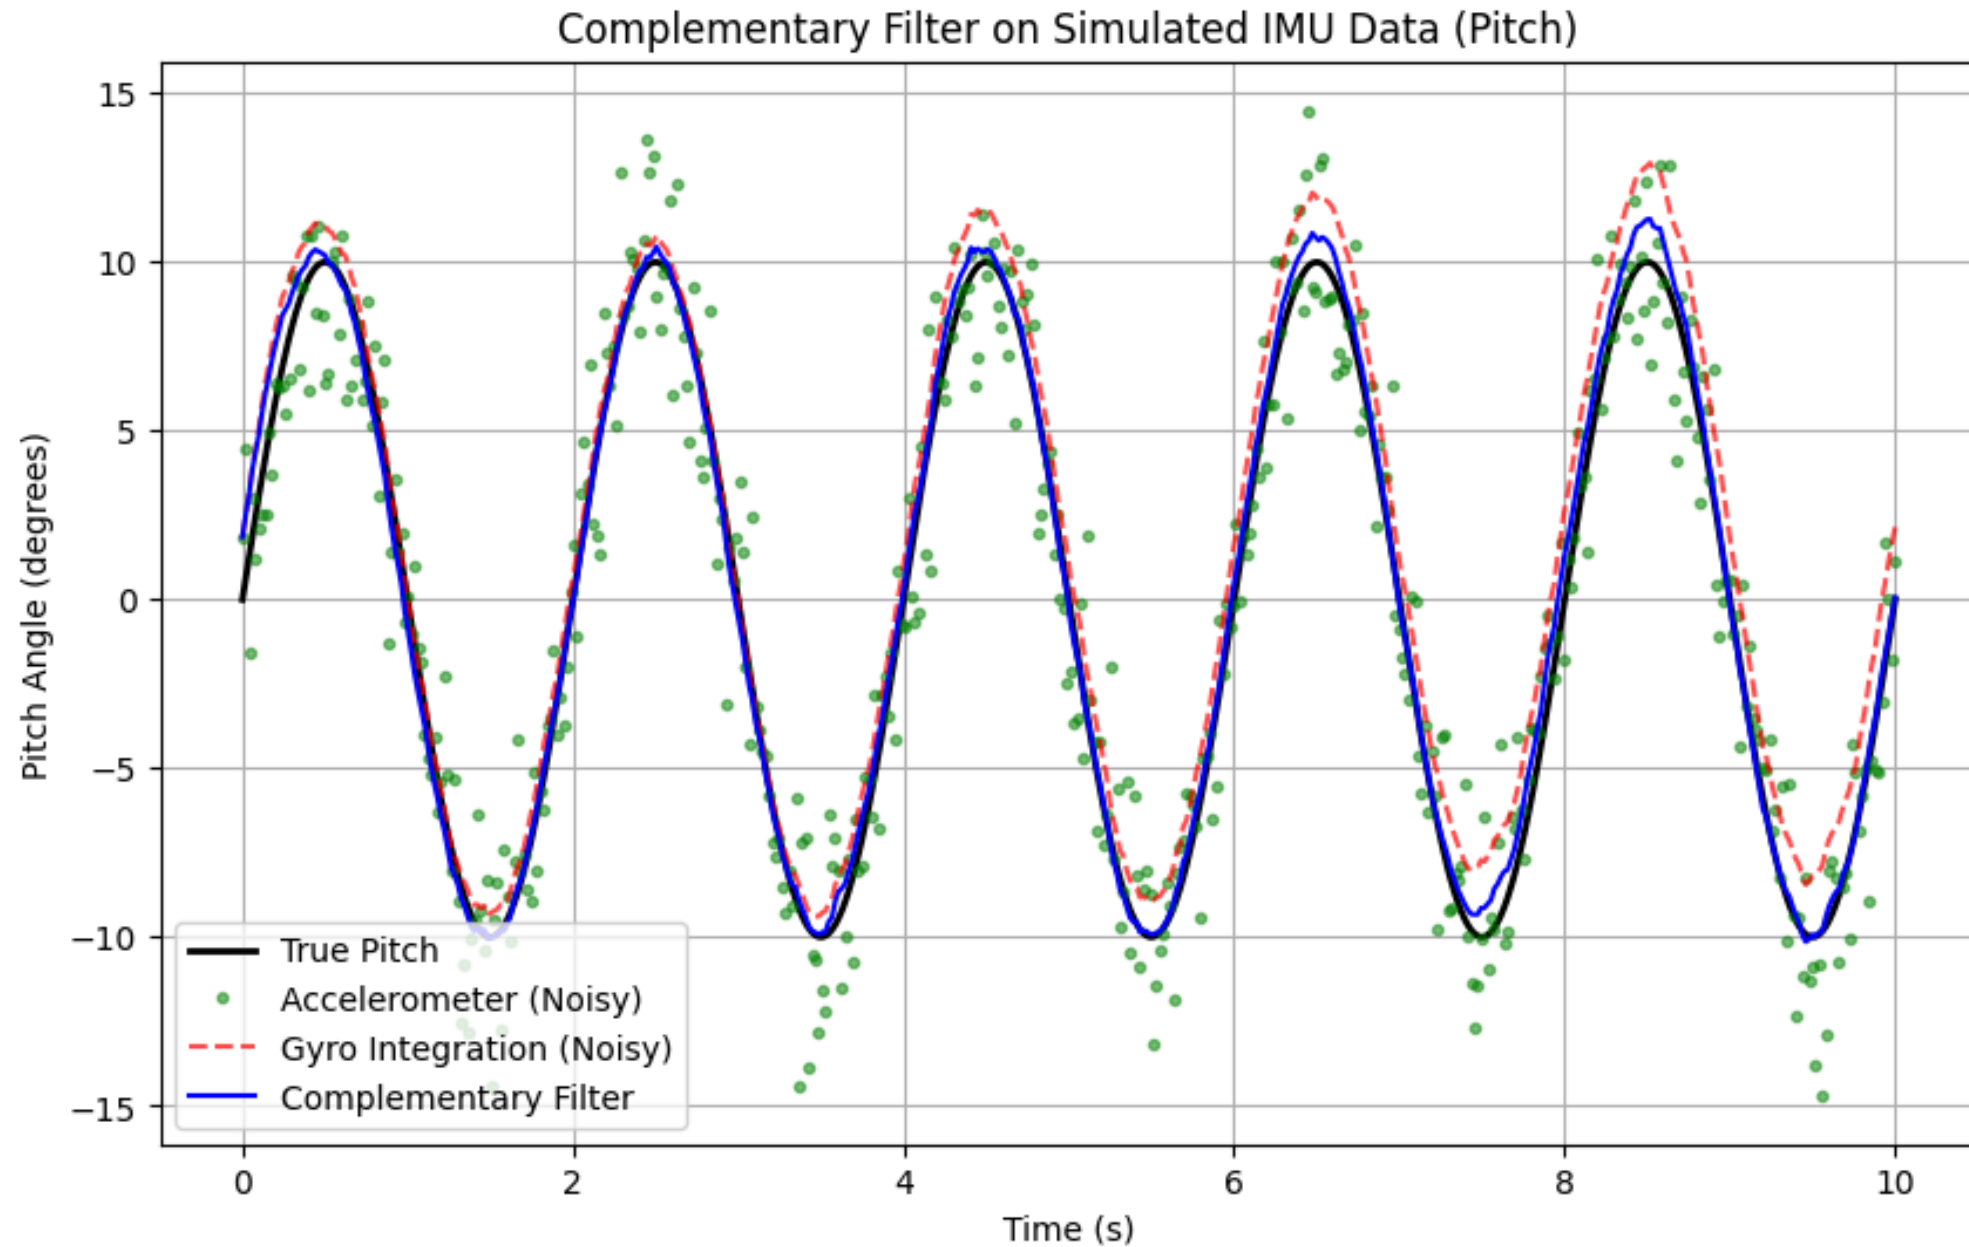
# 3. Menggabungkan data menggunakan Complementary Filter
alpha = 0.98 # bobot untuk gyro (umumnya 0.95 - 0.99)
comp_angle = np.zeros_like(time)
comp_angle[0] = acc_pitch_noisy[0]

for i in range(1, len(time)):
    # Integrasi gyro
    gyro_integration = comp_angle[i-1] + gyro_rate_noisy[i] * dt
    # Sudut dari accelerometer
    acc_angle = acc_pitch_noisy[i]
    # Rumus complementary filter
    comp_angle[i] = alpha * gyro_integration + (1 - alpha) * acc_angle

# 4. Visualisasi hasil
plt.figure(figsize=(10, 6))

plt.plot(time, true_pitch, 'k-', label='True Pitch', linewidth=2)
plt.plot(time, acc_pitch_noisy, 'g.', alpha=0.5, label='Accelerometer (Noisy)')
plt.plot(time, gyro_angle, 'r--', alpha=0.7, label='Gyro Integration (Noisy)')
plt.plot(time, comp_angle, 'b-', label='Complementary Filter')

plt.title("Complementary Filter on Simulated IMU Data (Pitch)")
plt.xlabel("Time (s)")
plt.ylabel("Pitch Angle (degrees)")
plt.legend()
plt.grid(True)
plt.show()
```

Techniques for Sensor Fusion

Sensor fusion adalah teknik menggabungkan data dari beberapa sensor untuk mendapatkan informasi yang lebih akurat dan andal.

1. **Weighted Averaging:**

- Kombinasi linear dari beberapa sumber data dengan bobot tertentu.
- Contoh: Menggabungkan suhu dari beberapa sensor untuk meningkatkan akurasi.

Konsep Sensor Fusion dengan Weighted Average

- Jika kita memiliki dua sensor yang mengukur variabel yang sama (misalnya, suhu atau sudut), kita dapat menggabungkan keduanya menggunakan rata-rata berbobot:
- $x_{\text{fused}} = w_1 x_1 + w_2 x_2$
- $w_1 + w_2 = 1$
- x_1 dan x_2 adalah nilai dari masing-masing sensor.
- w_1 dan w_2 adalah bobot berdasarkan tingkat kepercayaan sensor.

Contoh Kasus Weighted Average: Sensor Fusion untuk Suhu

Misalkan kita memiliki:

- **Sensor A** (akurasi lebih tinggi, noise lebih kecil)
- **Sensor B** (akurasi lebih rendah, lebih banyak noise)

```
import numpy as np
import matplotlib.pyplot as plt

# 1. Simulasi data suhu sebenarnya
np.random.seed(42)
time = np.linspace(0, 10, 500) # 10 detik, 500 sampel
true_temperature = 25 + 2 * np.sin(2 * np.pi * 0.1 * time) # Suhu sebenarnya berubah perlahan

# 2. Sensor A (akurasi tinggi, noise rendah)
sensor_A = true_temperature + np.random.normal(0, 0.5, size=len(time)) # noise  $\pm 0.5^{\circ}\text{C}$ 

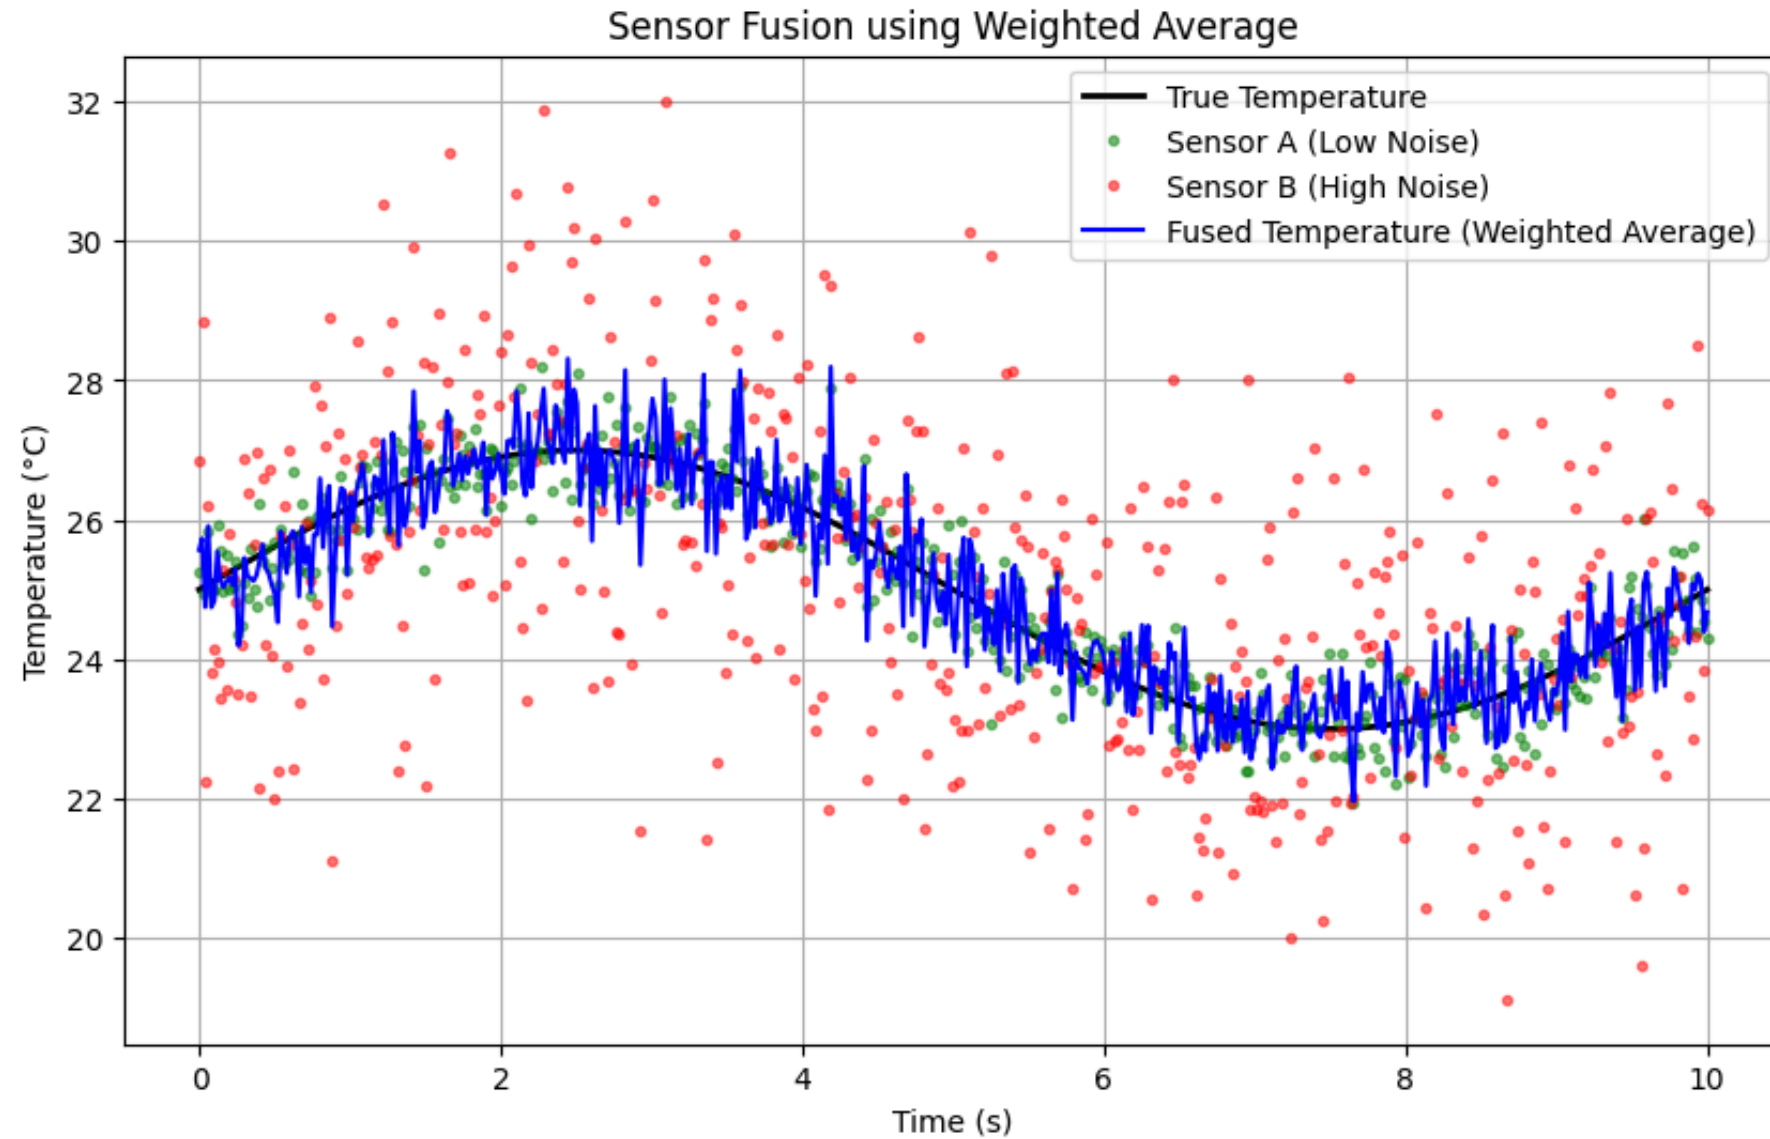
# 3. Sensor B (akurasi rendah, noise tinggi)
sensor_B = true_temperature + np.random.normal(0, 2, size=len(time)) # noise  $\pm 2^{\circ}\text{C}$ 

# 4. Bobot berdasarkan akurasi (misal: bobot invers dari variansi noise)
w_A = 0.8 # Sensor A lebih akurat
w_B = 0.2 # Sensor B kurang akurat

# 5. Sensor Fusion menggunakan weighted average
fused_temperature = w_A * sensor_A + w_B * sensor_B

# 6. Visualisasi hasil
plt.figure(figsize=(10, 6))
plt.plot(time, true_temperature, 'k-', label='True Temperature', linewidth=2)
plt.plot(time, sensor_A, 'g.', alpha=0.5, label='Sensor A (Low Noise)')
plt.plot(time, sensor_B, 'r.', alpha=0.5, label='Sensor B (High Noise)')
plt.plot(time, fused_temperature, 'b-', label='Fused Temperature (Weighted Average)')

plt.title("Sensor Fusion using Weighted Average")
plt.xlabel("Time (s)")
plt.ylabel("Temperature ( $^{\circ}\text{C}$ )")
plt.legend()
plt.grid(True)
plt.show()
```



2. Bayesian Filtering:

- Digunakan untuk estimasi probabilitas, termasuk **Kalman Filter** dan **Particle Filter**.
- Cocok untuk **lokalisasi** dan **tracking objek**.

3. Deep Learning-Based Fusion:

- CNN atau LSTM dapat digunakan untuk menyatukan data sensor dalam analisis kompleks.
- Contoh: **Multi-modal sensor fusion** pada self-driving cars.

Use Cases: Posture Tracking & Wearable Devices

a. Posture Tracking

- **Sensor yang digunakan:** IMU (accelerometer + gyroscope), kamera depth seperti Kinect atau LiDAR.
- **Metode:**
 - Menggunakan complementary filter untuk menyaring data IMU.
 - Kalman Filter untuk estimasi postur secara real-time.
 - Deep learning (LSTM) untuk analisis pola gerakan tubuh.
- **Aplikasi:** Pemantauan postur kerja, fisioterapi, game berbasis gerakan.

b. Wearable Devices

- **Sensor yang digunakan:** ECG, PPG, IMU, SpO2, suhu tubuh.
- **Metode:**
 - **Sensor fusion** untuk mendapatkan detak jantung yang lebih akurat dari PPG & ECG.
 - **Noise filtering** pada data biosignal dengan Kalman filter.
- **Aplikasi:** Smartwatch, pelacakan kebugaran, deteksi dini penyakit.